

HideEvolve

严格实验日程与预注册协议

同行代码直接作基线 · 唯一核心方法假设 · 程序级自主水印算法发现

V5.0 / 2026-10-09

启动 2026-10-12

核心实验至 2027-01-31

机动至 2027-02-28

研究目标

使用 Foundation Model Agent 自主生成完整的图像盲水印程序（嵌入、可选同步、提取），以区域删除与几何失步的复合攻击为高难度任务；比较通用程序演化与水印领域新变异机制在同等成本下的算法发现能力。

研究假设（不是已成立结论）：水印语义约束的联合程序变异可能改善嵌入—同步—提取的结构协同搜索效率。只有在 **G1/G2** 的证据支持下才继续开发，并通过 **G3/G4** 的预注册实验最终检验。

00 | 计划的约束与优先顺序

- 不重新造轮子：**ShinkaEvolve 为主算法发现基线，ReEvo 为第二算法发现基线；WAM、OrthoMark、SSyncOA 仅作水印算法性能/机制参照。
- 不锁死 DCT/QIM：**旧方法仅用来确认 evaluator 接口可运行，候选可采用不同载体、编码、同步与判别规则。
- 不混淆复现与论文结果：**公开仓库可访问不代表本地已跑通；同一载荷/分辨率/攻击下重测才能公平比较。
- 严格阶段冻结：**数据划分在 W02 冻结，复合攻击在 W09 冻结，正式实验方案在 W12 冻结，盲测仅 W15 开启。
- 不预设论文成功：**实验阴性即写入事实；W08/W12 未过门槛必须及时调整而不是继续扩张研发。

01 | 现有成果如何复用（先查复现成本）

角色	同行项目	官方代码复用策略及限制
主搜索基线	ShinkaEvolve · ICLR 2026	使用原版代码、默认演化机制及可配置 evaluator；我们的模块在 同一宿主 可切换。W01 锁版本，W03 正式摸底。
独立搜索基线	ReEvo · NeurIPS 2024	直接适配其搜索入口；W10 前最多投入 2 个工作日适配，若不可行如实列为未完成，不能用自制“近似 ReEvo”冒充。
必需内部对照	Shinka 原版 / 原版+筛选 / 原版+新模块	将“有效性过滤”与真正的成对程序变异区别开来，公平计算额外 Token 和重试。
图像水印	WAM · ICLR 2025	官方局部消息水印，优先官方 32-bit 设置；仓库于 2026-08 归档，固定权重和许可证。
图像水印	OrthoMark · ICML 2026	官方 64-bit 鲁棒权重起步；不能把 64-bit 与 32-bit 直接排出绝对优劣。
条件性几何水印	SSyncOA	对象裁剪-粘贴与几何同步参考，必须确认对应任务/权重是否可复现；超时不阻塞主线。
攻击及评测	WAVES · ICML 2024	重用适用的 distortion 与度量；复合攻击编排自行增加，并记录更改。

AutoMark（文本水印）与 CASIAL（图像几何水印）用作文献方法、缺陷与困难任务定义的参照，不直接当作已确认可运行的图像搜索/性能基线。

02 | 实验任务和不可更改的基本协议

项目	严格规则 / 可操作定义
候选输入输出	embed(X,M,K) → Y; decode(A(Y),K) → M 。允许算法定义独立同步/预处理模块，但必须可执行、可复跑。
严格盲提取	提取程序只可看到受攻击图像、公开固定协议和密钥； 禁止 读取原图、原消息、攻击参数真值、评测随机种子、开发外部答案文件。违反即无效，不参与分数比较。
主任务建议值	32-bit、256×256 RGB ，仅为初始一致化配置；W02 依模型支持与成本正式冻结，不得在 W13 看到结果后更改。
可行性门槛	载荷完全一致；无攻击正确恢复经随机消息/密钥验证；图像质量以同一 PSNR 门槛（建议起步 ≥35dB，但由 W02 小样本及业务要求冻结）约束。失真、超时、OOM、崩溃统一计入失败。
攻击层级	A0 无攻击；A1 JPEG Q75、单独旋转、缩放；A2 裁剪重缩放和局部擦除；A3 旋转/缩放 + 裁剪/擦除组合。裁剪占比指 被删除的像素面积 ；变换顺序与重采样方法全部配置化。
攻击真值	几何真值仅供 evaluator 故障诊断；候选 decode 接口绝不可见。oracle 校正的 BER 只能作失败定位附加指标。
密钥/消息	由独立随机数发生器按样本生成；不可固定同一消息；攻击端密钥与检索端密钥一致，搜索日志不得泄露答案给候选。
分类口径	合法率 = 满足协议的候选 / 全部已提出候选；有效候选率 = 同时符合无攻击可恢复及画质/时间约束的候选 / 全部已提出候选。不能把无效提议从分母删除。

数据隔离：不同用途不可互换

集合	允许用途	冻结规则
D-search （开发）	LLM 搜索中的奖励和候选筛选	W02 固定清单与顺序。
D-select （开发验证）	调评价器、分析失败、选算法	W02 固定；不能向候选代码提供答案。
D-test （真正盲测）	只有 W15 选模冻结后开启一次正式统计	必须与旧 Stage 1-8 用过的 1000 张开发 COCO 图像及本次所有开发集去重；图像来源、近重复检测和清单哈希存档。样本量 W12 用先导方差/效应量计划确定。

先导可从既有开发图像中抽取，但从未使用过的盲测集应另行准备。由于未知最终硬件、统计功效和成本，盲测规模不可无依据写死为“600 张即可”。

03 | W01-W04：先运行同行原版，再审查确切瓶颈

周次	执行工作	当周验收标准（必须留下证据）
W01 10.12-10.18	环境审计 + 主基线可运行 盘点现有 HideEvolve 框架、设备、额度、数据来源；固定主仓库版本；按官方说明运行 ShinkaEvolve 自带示例两次；编制 ReEvo 接入风险表。	提交 env-lock、commit SHA、设备/费用表、两次运行日志与报告；不能跑通时留下可复现的环境故障，而非静默跳过。
W02 10.19-10.25	程序级任务与验证器 v1 定义 embed(image,message,key) 与 decode(attacked_image,key)，允许自由算法结构；移植旧 evaluator 可复用部分、WAVES 中适用攻击；隔离图像/密钥/攻击真值；建立搜索/开发验证/盲测清单。	接口契约、攻击 v0、自动测试与基准算法冒烟测试全部通过；确认盲提取无原图/原消息/真值泄露。
W03 10.26-11.01	官方 Agent 原版摸底 用原版 ShinkaEvolve 搜索完整程序对，另设直接 LLM 联合改写内部参照；同初始解题信息，不强制复用旧 DCT/QIM。	至少 3 条独立 pilot 轨迹，每条计划最多 30 个候选；记录候选内容、失败类型、LLM token、执行成本和最佳可行分数。
W04 11.02-11.08	文献证据 + 瓶颈核实（G1） 审查无效程序、盲提取违规、数学不匹配、几何失步、结构重复；对照 AutoMark/CASIAL/OrthoMark 与 GP 水印先例；给候选方法做新颖性风险表。	G1 决策备忘录：一个可证伪的核心机制假设、至少 3 个可重现的对应失败例、初步对照与退出标准；不满足则不锁定模块。

前两周按工作日落实到人和文件

日期	当日任务	必须留下的产物
10/12 周一	检查旧 Stage 1-8 代码与 PoC，锁定现有 Git 版本与环境。	repo_audit.md / hardware.yaml
10/13 周二	安装官方 ShinkaEvolve，不修改核心源码。	install.log / requirements.lock
10/14 周三	跑官方示例，两次独立结果；定位调用、评价器接口。	run_A、run_B / 日志截图
10/15 周四	估测每次模型调用、候选评价的费用和时间；核查 ReEvo。	cost_probe.csv / baseline_manifest.yaml
10/16 周五	W01 检查点；不能重跑则产出故障隔离方案。	W01_review.md
10/19-20	定义可运行 embed/decode 协议，复用旧 evaluator。	protocol_v1.md / runner.py
10/21-22	实现基础攻击、图像分流、无泄露与超时测试。	attacks_v0.yaml / test_contract.py
10/23 周五	W02 检查点，冻结三类数据清单与基础协议。	dataset_manifest.sha256 / W02_review.md

G1 / 11 月 8 日：必须有可重跑的原版搜索轨迹，明确标注“嵌入/提取不一致”“几何鲁棒性不足”“重复现成模板”等失败类别；若证据不支持所设模块，则改研究假设，不因先有 PoC 就强行继续。

04 | W05-W08：只开发一个可证伪的新机制

周次	执行工作	当周验收标准
W05 11.09-11.15	联合变异模块规格 若 G1 支持结构依赖瓶颈，则定义共享语义表示、变化影响范围、可生成约束；明确 Agent 自主发现什么、人只固定什么；列出不支持的程序类别。	spec.md、接口草图、至少 3 种非同构水印规则用例、硬约束/软约束清单；必须保留通用代码直接变异入口。
W06 11.16-11.22	可插拔实现 + 正确性测试 在同一个 ShinkaEvolve 宿主中加入可开关算子；配套静态依赖提取/LLM 语义判断/约束构造/成对变异；测试超时、执行沙箱与日志。	v0 模块、最小复现脚本、≥30 个接口/异常测试、≥3 个不同数学结构的程序配对案例；错误不可隐藏为成功。
W07 11.23-11.29	公平先导比较 两条主臂：原版 ShinkaEvolve 和原版+模块；第三臂 ‘只加有效性筛选’ 以隔离工程过滤作用；同模型、同种子池、同候选/预算上限。	每臂拟 3 seeds×30 个候选；输出合法率、结构有效候选、同成本最优鲁棒分数、耗时/Token、原始轨迹；不得只看旧解码器失效对照；ReEvo 接入最多安排 2 个工作日。
W08 11.30-12.06	机制消融与止损（G2） 检验增益来源于成对构造还是额外过滤、重试或调用次数；参考 DeltaEvolve/ShinkaEvolve 既有通用方法查重；必要时重构一种明确新机制。	G2：独立复查 pilot，出具效果方向和不确定性；若无性能/效率改善或仅增加检查步骤，停止将其当核心创新。

新模块必须讲清楚的三件事

- **输入：**当前可执行水印程序 + Agent 提出的算法数学结构变化（例如载体、判别、同步表达式）。
- **核心动作：**分析影响范围，形成跨嵌入/同步/提取的共享约束并生成协调的结构级修改；必须允许实际数学关系变化，不能只提供预定义 QIM 模板菜单。
- **输出与失效：**新程序、变更证明/约束报告、未满足项；不能合成时回退通用代码变异，回退与失败均计入成本。

G2 必需三臂对照

实验臂	差异	目的
B0：原版	未经修改的 ShinkaEvolve 搜索策略	主公平基线。
B1：原版+筛选	只做新增约束检查/失败反馈，不生成对生成	识别“过滤无效程序”本身的收益。
M：原版+模块	加入语义关联的联合程序变异	测试合成机制是否提供额外收益。

同等预算：三臂使用相同基础模型/温度设置、相同候选入口、相同数据和候选评价器；建议 3 seeds × 每臂最多 30 次候选，且汇报实际 Token/金额/CPU-GPU 时。模块增加的推理调用要计入总成本；预算用尽立即终止。

G2 / 12 月 6 日：若 M 的收益仅表现为“生成程序更合法”，但同成本下可行且鲁棒的算法质量无改善，则合成器暂视为工程模块；无一致方向的收益则停止新增功能，先分析原因。先导样本不支撑统计显著性宣称。

05 | W09–W12：困难任务与公开水印基线

周次	执行工作	当周验收标准
W09 12.07–12.13	复杂攻击矩阵 v1 冻结 明确裁剪重缩放 vs 区域擦除 vs 对象裁剪粘贴，分别构造旋转/缩放/删除及复合攻击；定义搜索可见攻击与盲测未知强度。	攻击配置 SHA、每种攻击的参数范围及组合顺序、10 张图像人工复核示例、泄露检查全部通过；禁止进入盲测池查看结果。
W10 12.14–12.20	直接复现同行水印系统 优先复现 WAM 32-bit 和 OrthoMark 官方 64-bit 设置；SSyncOA 最多用 2 个工作日检查依赖与权重并决定是否纳入；WAVES 做统一攻击封装。	基线 manifest：论文/仓库/commit/模型权重/许可证/分辨率/载荷/运行命令/失败原因；只在可比条件下汇总排名。
W11 12.21–12.27	困难任务下的结构发现 pilot 用冻结的攻击开发集测试主方法与原版框架；归档非参数级变异，包括区域分配、同步、嵌入判别等；核实每个‘新规则’并非已公开模板的改名。	≥3 组配对 pilot 轨迹与 Top-K 完整程序；每个 Top-K 有可重跑日志、失效拆分及算法机制图。
W12 12.28–01.03	正式协议预注册（G3） 据前期观察与成本确定最终预算、主终点、独立种子数、选模规则、盲测图像量与置信区间方法；冻结所有 Prompt、攻击参数与评价器。	G3：预注册 PDF/YAML + git tag + 数据清单哈希；至少 1 个可解释的非平凡候选；未达标则缩题或停止大规模正式运行。

复合攻击矩阵：W09 冻结后不得挑选有利强度

攻击族	建议开发强度示例（W09 固定）	盲测条件
JPEG / 噪声	JPEG Q75；可附单一受控轻噪声	另外保留 Q65 等未见强度，不能用于搜索。
旋转、缩放	旋转 $\pm 5^\circ/\pm 15^\circ$ ；缩放 $0.8\times/1.2\times$	未见角度和缩放组合，并报告黑边/填充策略。
裁剪/区域擦除	删除 10%/25% 面积；中心、随机/对象相关位置分层	明确裁剪后是否重缩放与擦除填充值。
复合攻击（主难点）	旋转+局部擦除，缩放+裁剪，按固定顺序	未见参数组合；区别各攻击族并逐项报告。

以上数值是协议设计建议，不是既有论文复现实测强度；以 W09 冻结的完整配置为最终准则。不要用攻击的已知旋转角或裁剪框帮助候选解码。

G3 / 2027 年 1 月 3 日：必须锁定主终点、规则、总预算、样本划分与统计方法，同时形成可解释的 Top-K 算法机制档案。无法确认非平凡结构贡献则暂停大规模搜索并调整论文问题。

06 | W13–W16：正式实验、一次性盲测与论文

周次	执行工作	当周验收标准
W13 01.04–01.10	正式算法搜索 I 仅用冻结配置运行 ShinkaEvolve 原版与新方法；种子成对，失败照算预算；收集所有失败样本与模型费用。	完成正式重复的约一半；实验运行清单、日志、checkpoint；不得根据中途成绩修改 Prompt 或候选预算。
W14 01.11–01.17	正式算法搜索 II + 第三基线 完成两主臂剩余重复；条件允许则接入已复现的原版 ReEvo，按预注册单独对照；出同成本 best-so-far 曲线。	两主臂计划各≥5 seeds；记录每种方法确切模型、候选数、Token、GPU/CPU 时和失败率；生成基本统计图。
W15 01.18–01.24	唯一一次正式盲测 + 泛化 按 W12 选模规则锁定算法并测试独立盲测图像；报告无攻击、单一与复合攻击 BER/全消息成功率/质量；与 WAM/OrthoMark 按相同载荷和分辨率分层比较。	盲测原始表、每攻击族结果、置信区间、未见攻击与图像来源变化分析；不得因盲测差而返回改算法再重测同一数据。
W16 01.25–01.31	统计消融 + 论文初稿 (G4) 补齐已预注册的‘去掉成对生成/只保留筛选’消融；逐样本统计、效应量、置信区间；写方法、相关工作与威胁分析。	G4：论文 V1、主图表、结构解释、全部代码与随机种子清单；结果阴性也真实呈现，不采用只挑最好种子的图。

正式实验预算：W12 签字冻结

项目	严格处理方式
主搜索重复	计划 5 个独立随机种子 / 主实验臂 (B0、M)；同样 seed list 成对使用；每个种子拟 60 个候选评价上限，以及一致的 Token/费用或运行时间上限；经 W01–W03 成本估算后可在 W12 一次性调整并公开记录。
两种公平观察轴	同时画出 best feasible quality vs. total tokens / cost 和 best feasible quality vs. evaluated candidates；若约束构造额外耗费模型调用，不得只报候选数公平。
选模规则	每个 run 只能按 D-select 与冻结的优先级选定最优可行程序；不允许看过 D-test 后挑第二名。
消融	至少 B0、B1、M 三臂；如果 M 有多个明确独立机制，再分别删除，不为了凑“多个创新点”盲增实验。
统计分析	搜索运行单位是 seed；报告逐 seed 原始数据、均值/中位数、95% 置信区间与配对效应量。图像级 BER 以图像及消息试验为样本层级，必要时用分层 bootstrap，不能将像素或 bit 当成独立实验重复。
阴性结果	如果新模块没有明显改善，同样保留图表并修改贡献表述；不得只展示最佳 seed。

核心评价指标（写入预注册）

- **主要终点：**搜索主指标：固定总搜索成本下 D-select 所选最佳可行候选在预定义复合攻击的消息级成功率；真正鲁棒性主证据：同一选模规则产生的候选在 D-test 的消息成功率和 BER。两套结果均报告，聚合权重在 W12 冻结。
- **辅助终点：**首次发现达到给定 BER/失真阈值所需成本、有效候选率、PSNR/LPIPS、每个攻击族的 BER、嵌入与解码运行时延。
- **探索的科学证据：**至少展示一个自动发现的完整数学规则及其前后变更、现成模板排查、真实程序、可复现无泄露日志；“自动发现”不是改变量化步长。

07 | 四个硬关口（GO / REVISE / STOP）

时间	GO 的最低证据	REVISE / STOP 的触发与动作
G1 11/08	已得到≥3 条可重现的原版 Agent 程序搜索轨迹；任务验收器工作正常；至少一个频繁出现、与水印结构有关的限制被具体定位。	如果无法跑通原版框架：一周内集中修复接口；若真实失败主要是 prompt/环境问题，优先修工程，不开发伪创新。
G2 12/06	有公平三臂先导对照；M 相比 B0/B1 在至少一个预注册的可行算法发现效率指标上显示方向一致的改善，并有机制例子。	若无增益：终止模块扩展；若仅提高合法率：定位为工具，另找可研究的结构搜索问题。
G3 01/03	候选有真实结构改变；困难任务能运行；正式方法与公允性规则全部冻结、预算可承担、D-test 完整隔离。	若没有非平凡算法或难以跑通复合攻击：缩小任务、延期正式试验；不要把旧 DCT/QIM 调参当作完整算法发现。
G4 01/31	两主臂、消融、统计和盲测齐备；算法质量与代价真实呈现；初稿含威胁与限制。	若效应证据不足：只补预先定义的关键缺口，不用盲测成绩反向设计新算法并宣称零样本泛化。

工作周制度与风险处理

- **每周一 09:30**：确认本周唯一核心实验、资源配额与负责人（如仅由本人执行，负责人填本人）。每周三 18:00：中期检查。每周五 18:00：提交对应交付物和简短决策记录；周末主要作为缓冲，不假设无偿加班。
- **失败重试**：网络/API 故障重试次数预先规定；模型生成无效代码、超时或解码失败不得删除记录。所有随机数、代码哈希、模型参数、攻击配置、依赖版本连同结果入库。
- **设备/成本未知**：W01 得到资源表后安排真实并发，W12 前由导师确认能否承担 5 seeds×60 次等规模；无预算时在所有臂同步缩减规模，不能偷偷删弱臂。
- **第三方复现止损**：单个条件性基线最多 2 个工作日；记录不可复现原因（权重、依赖、许可证、分辨率），换成已有可运行基线，不用自行写一个不同算法来冒充。

2 月机动期（不是默认追加研究周期）

日期	限定任务
W17 02.01–02.07	按 G4 缺口补齐预先指定的必要实验；修复复现脚本、重跑故障而非改评价定义。
W18 02.08–02.14	完成导师/师姐实质性修改，补充同一实验协议下的精度或公允性证据。
W19 02.15–02.21	论文英文润色、图表复查、许可证审计、开源排除凭证、期刊候选筛选。
W20 02.22–02.28	完成投稿准备稿和内部答辩；未满足 G4 时明确延期及原因，不能虚报已投稿。

08 | 必须提交的项目文件与论文证据清单

可复现文件	具体内容
repro/baseline_manifest.yaml	ShinkaEvolve/ReEvo/WAM/OrthoMark/SSyncOA 对应 DOI/官方仓库、SHA、权重来源、许可与兼容性状态。
configs/protocol_v1.yaml	载荷、分辨率、质量阈值、盲提取协议、攻击列表、攻击顺序、超时/异常分值。
data/splits_*.sha256	D-search、D-select、D-test 的数据来源与完整 hash；独立盲测的访问记录。
experiments/run_manifest.csv	方法臂、seed、模型、提示版本、候选/Token 上限、运行日期、成本、代码 SHA 和容器信息。
results/candidates/	每个候选的原始代码、生成提示、错误、是否盲提取合法、无攻击和分层攻击结果。
analysis/paired_statistics.ipynb	预注册主终点、逐 seed 统计、置信区间、失效分类、每臂成本和统计脚本。
paper/	数学机制、算法结构演化图、主对照、消融、未见攻击、与同行算法公平协议及局限。

论文中必须同时展示的四张主图

- 图 1：新模块输入—依赖推导—成对程序变异—评测反馈流程，清楚标注 Agent 与人工约束的责任边界。
- 图 2：同等 Token/费用下，搜索得到的最佳可行鲁棒表现曲线（每 seed + 95% CI）。
- 图 3：原版、只有筛选、联合变异的有效候选率和困难攻击表现；避免只给平均单一分数。
- 图 4：Agent 真实发现的算法数学关系、载体/同步选择、攻击可视化，以及与已有论文结构差异。

参考文献与官方复用入口（在线核查：2026-10-09）

项目	官方入口
ShinkaEvolve	github.com/SakanaAI/ShinkaEvolve
ReEvo	github.com/ai4co/reevo
WAM	github.com/facebookresearch/watermark-anything
OrthoMark	github.com/QQiuyp/OrthoMark
SSyncOA	github.com/zcx-language/SSyncOA
WAVES	github.com/um-d-huang-lab/WAVES
AutoMark / CASIAL（文献）	github.com/eth-sri/automark ； arxiv.org/abs/2607.26729

声明：这是一份未来实验执行协议，不是已完成实验记录。数值预算、设备资源及某些模型权重的实际可用性需在 W01–W12 中按要求核实/冻结，不能把计划中的条件当成已经验证的研究结果。接受 G1–G4 不等于保证 SCI 论文录用。